

Open-then-Audit: 公開モデル計算のためのピア・ツー・ピア・プロトコル

Open-then-Audit Research

Revision 1.3 – 2026

概要. 大規模な決定的モデル計算を全 node が再実行すれば、検証費用は node 数に比例する。選出 committee へ委ねれば計算は減るが、結託と停止の仮定が戻る。本稿は Open-then-Audit を提案する。Worker は厳密整数で定義された計算を一度だけ実行し、出力と checkpoint trace へ commit し、一回限りの open を確定した後でのみ、bonded threshold beacon から監査位置を受け取る。Node は先頭、末尾、および少数の内部区間だけを再実行する。Value-bearing profile では、bonded registry から将来乱数で選ばれた replayer が full replay を行い、clean か fraud かに関係なく固定 fee を受ける。発見された不正は最初の不一致区間で非対話的に反証され、Worker escrow、false-clean replayer bond、未成熟 reward へ自動執行される。Reward は実際に実行された non-padding work へ比例し、padding は零報酬である。安全性は、任意の不正区間集合が節約できる費用、beacon の再試行上限、実効 full-replay 率、および haircut 後担保価値を用いて評価する。本方式は少数 sampling を semantic correctness の完全証明とは扱わず、権威ある出力は全量 full replay または別の完全 proof を要求する。

1 序論

公開モデル計算を報酬化するには、第三者が仕事の実行を確認できなければならない。全 node の full replay は trust を減らす、同じ高価な計算を network 全体で繰り返す。Replica、refereed delegation、interactive verification game は重複計算を減らす一方、server 独立性、対話、availability、incentive 設計を追加する。Open-then-Audit は、Worker を先に一つの trace へ拘束し、open 後の乱数で全 node が少数区間を直接検査し、後の反証を非対話的な first-divergence proof へ縮約し、さらに protocol-funded な bonded full replay を組み合わせる。

必要なのは、Worker が検査位置を知る前に一つの実行へ拘束され、通常 node は有界な計算だけを行い、false claim が後から見つかった場合には Worker の応答なしで短い proof へ変換できる仕組みである。ただし、浮動小数点の実装差、full-attention の巨大 witness、怠惰な replayer、host block hash の grinding、早期 EOS と padding を放置すれば、sampled audit の式だけが美しく残り、実際の安全性は消える。

Open-then-Audit は、厳密整数計算、work 比例報酬、commit、不可逆 open、bonded future beacon、sampled audit、bonded full replay、first-divergence proof の順でこれら进行处理する。Protocol は特定の blockchain、token、fork-choice、model へ依存しない。Host は ordering、attestor-finality、threshold entropy、data availability、escrow、evidence inclusion を提供する。

2 正準計算と work accounting

Value-bearing claim の machine description C は、model または program、weights、tokenizer、入力 encoding、固定幅整数または固定小数点算術、requantization、rounding、operation order、routing、termination、checkpoint rule を一意に固定する。Floating point は value-bearing validity path で禁止する。全中間値は公開 range proof または静的 bound により overflow しないことを示し、checked overflow が発生した実行は invalid とする。Batch size、thread count、kernel fusion、CUDA、ROCm、Metal 等の実行環境が変わっても transition 列は同一でなければならない。

Rounding registry は少なくとも、accumulator 境界、requantization の tie、signed shift、saturation、MoE router output の量子化と tie-break を固定する。独立した二実装が通常 vector だけでなく、これらの境界を強制する negative/differential corpus で bit-exact 一致しない計算定義を value-bearing profile へ有効化してはならない。

実行を q 個の区間へ分ける。

$$s_{i+1} = F_i(s_i), \quad 0 \leq i < q.$$

各 reward-bearing 区間は同じ canonical work quota K を持つ。以下、 $q = n_w$ を non-padding の reward-bearing 区間数とし、監査母集団、報酬、および後の確率式から padding を除外する。正準実行が EOS へ到達した後の残り shape は、

$$D_{i+1} = H(D_i \parallel \text{PAD} \parallel i)$$

という零 cost、零 reward の padding transition だけを持つ。Claim reward または抽選 weight は、実際の non-padding 区間

数 n_w へ厳密比例する。

$$R_{\text{claim}} = \rho K n_w. \quad (1)$$

したがって、Worker が虚偽の早期 EOS へ飛べば残り work の reward も失う。省略した区間の reward を請求するには、その各区間を work-bearing として commit しなければならず、虚偽区間集合 S に入る。Padding transition は random sample へ入らず、 q や defect fraction を水増ししない。これにより、reward-bearing work について

$$C_{\text{saved}}(S) \leq K|S| \quad (2)$$

を規範的に成立させる。Accounting-only padding で残り work を実行済みと数える方式は禁止する。

Worker は各境界 digest を

$$D_{i+1} = H(D_i \parallel A_i \parallel \Delta S_i \parallel U_i)$$

として記録する。 A_i は operation accumulator、 ΔS_i は changed-state commitment、 U_i は token/layer position、KV length、append-only KV root、attention position、router state、selected expert、expert accumulation order、quantization scale、rounding、termination、padding、RNG 等、次の transition へ影響する全 mutable state を含む。

Worker は model を一度だけ full execution し、 $D_0, \dots, D_q$ を incremental に生成する。18 区間監査は 18 回の推論を意味しない。証拠用に第二回 full inference を要求せず、checkpoint ごとの全 state 再 hash、巨大 tensor の同期 copy、global accelerator 同期も安全性の前提にしない。




図 1 Worker は全 trace へ commit する。Node は境界区間と将来乱数で選ばれた内部区間だけを再実行する。

3 Commit、Open、bonded beacon

Worker は output commitment、checkpoint-vector root、vector の data-availability manifest、non-padding work count、専用 escrow を含む ExecutionCommit を公開する。Commit が attester-final になるまで次段階へ進まない。Open 前に commit が expiry した場合、専用 escrow は non-refundable attempt fee を除いて返還される。

Commit finality 後、Worker は一回限りの OpenAnnounce を公開する。Open は output、execution seed、checkpoint vector の encoding を明らかにし、元の commit を参照する。同一 commit の二回目の open は invalid である。Audit entropy は OpenAnnounce が attester-final になった後にだけ生成する。

Value-bearing host は block hash 単独を監査 entropy に用いてはならない。Host は bonded attester set による threshold commit-reveal beacon を提供する。各 round では、DKG または同等の verifiable distributed setup により ρ_r を threshold secret-share し、Open finality 前に一つの commitment $C_r = H(\rho_r)$ を finalize する。Threshold 未満の share からは ρ_r を再構成できない。Open finality 後に一意な reveal share を公開し、任意の threshold 個の valid share は同じ唯一の ρ_r を再構成するため、reveal subset の選択で別 output を作れない。Share 不提出は attester bond の objective slash 対象である。Signature は share を認証するだけで、signature bytes 自体を entropy へ入れてはならない。

監査乱数は

$$R = H(\text{ClaimID} \parallel \rho_r \parallel \text{ParameterSetID})$$

である。Threshold 以上の attester が事前共謀すれば予測可能になるため、その collusion bound は host assumption として公開する。Round 全体が規定 deadline までに再構成不能な場合だけ新 round を開始できる。敵対 attester が burn 可能な bond 総額を B_{adv} 、失敗 round ごとの最小不可逆 slash を s_{min} とすると、Host は

$$g_{\text{max}} \leq 1 + \left\lceil \frac{B_{\text{adv}}}{s_{\text{min}}} \right\rceil$$

またはそれより保守的な上限を公開する。 g_{max} を価格付けできない host は value-bearing profile を有効化してはならない。

4 Sampled audit と KV availability

$q > 18$ では、node は先頭 I_0 、末尾 I_{q-1} 、および R から重複なしに選ばれた内部 m 区間を検証する。Reference 値は $m = 16$ で合計 18 区間である。 $q \leq 18$ では全区間を検証する。

選ばれた区間 j について Worker は D_j の state opening、operation accumulator、必要な model tile への Merkle path、claimed D_{j+1} を提出する。Node は F_j を一度実行し、 $D'_{j+1} = D_{j+1}$ の場合だけ pass とする。先頭は公開 job へ、末尾は output と終了 state へ trace を binding する。

Full attention では、選択区間が過去の KV prefix 全体を読む。KV state は append-only Merkle Mountain Range または同等の append-only commitment へ格納する。18 区間の package は各区間ごとに prefix を複製せず、最大 sample 位置までの canonical KV prefix を一度だけ運び、各 sample に prefix membership と consistency proof を添付する。Context 上限 c_{ctx} 、token 当たり KV bytes b_{KV} 、model tile witness W_{tile} について、profile は

$$W_{\text{max}} = c_{\text{ctx}} b_{\text{KV}} + W_{\text{tile}} + O(m \log c_{\text{ctx}}) \quad (3)$$

を数値公開し、data/evidence band を B_{DA} 、package deadline を Δ_{pkg} として

$$W_{\text{max}} \leq B_{\text{DA}} \Delta_{\text{pkg}} \quad (4)$$

を admission 条件にする。条件を満たさない long-context profile は sampled-audit tier へ入れず、full-replay-only tier とする。特に 128k 級 context は、release 固有 benchmark が式 (3)(4) を満たすまで full-replay-only である。

完全な ordered checkpoint vector、KV manifest、sampled witness は監査 entropy の前に客観的に data available であり、proof 期間中に host history から再構成可能でなければならない。Root と best-effort peer serving だけを DA と呼んではならない。

5 Bonded required replay

Sampled audit は広い省略へ強いが、一つの sparse junction を外し得る。Spendable reward を持つ profile は、各 Provisional claim を後続 beacon から確率 $r > 0$ で RequiredReplay へ選び、bonded replayer registry から k 個の異なる bond outpost を without replacement で割り当てる。First-come assignment は禁止する。Worker と同一 identity または同一 bond outpost は除外するが、Sybil 独立性を証明するものではない。

各 replayer は claim 専用 bond reservation を作り、canonical full replay を行い、ReplayRoot と clean/fraud result へ署名する。Clean でも fraud でも固定 fee を受け取る。Claim の maturity には、選出された k 枠について valid な completion statement が全て揃うことを要求する。一名でも fraud を示せば DefectProof を処理し、false claim を mature させない。No-show、invalid statement、期限超過は bonded penalty と有界な再 assignment を生む。総 audit horizon 内に k 件を完了できなければ reward を zero とし、Worker fault が無い限り Worker escrow を返還する。後に valid DefectProof が成立した場合、false-clean へ署名した replayer bond も slash される。

Replay statement は full replay の cryptographic proof ではなく、Worker の公開 root を copy する怠惰を暗号的に検出できない。したがって安全性は人数ではなく、攻撃 coalition が失う collateral で評価する。Worker と結託 replayer 集合 Q について

$$L_{\text{coal}}(Q) = L_W + \sum_{a \in Q} L_a \quad (5)$$

を用いる。単なる assignment 率 r を安全性へ数えてはならない。 p_{full} は、selection、beacon bias、operator 独立性、honesty、completion、proof inclusion を含む「少なくとも一回の非結託 full replay または permissionless full replay が期限内に DefectProof を生成可能にする確率」の保守的下限である。

Selected replayer には clean claim でも固定 fee を支払う。Permissionless reporter bounty は少なくとも実測 full replay p99 費用と margin を賄い、

$$B_{\text{report}} \geq C_{\text{replay}, p99} + \mu \quad (6)$$

を満たす。一方、自己通報で penalty の大半を回収できないよう、全 reporter payment は事前に定めた小割合へ cap し、

coalition の不可逆 loss を経済式へ用いる。Replay capacity または bond が p_{full} の公開下限を維持できない場合、新規 value-bearing admission を停止する。

権威ある model output を消費する profile は全 claim の full replay、すなわち $p_{\text{full}} = 1$ に相当する保証、または full execution correctness を示す別の complete proof を要求する。

6 Network、fraud proof、host 要件

Network は次の手順で動作する。

1. Worker が job を full execution し、trace へ commit し、claim 専用 escrow を lock する。
2. Attestor layer が ExecutionCommit を finalize する。
3. Worker が一回限りの OpenAnnounce を公開し、checkpoint vector と KV manifest を data available にする。
4. Attestor layer が open を finalize し、threshold beacon を reveal する。
5. Worker が sampled interval witness を broadcast し、node が有界再実行する。
6. Valid な claim を Provisional として受理する。
7. 後続 beacon が RequiredReplay と k replayer を選び、必要な claim の maturity を full replay 完了まで待つ。
8. Proof 期間中に valid DefectProof が入れば claim を Void し、無ければ条件を満たした claim だけを Mature する。

Full replay を行った者は、canonical sequence と Worker sequence が初めて異なる区間 j^* を求める。最小性により開始 state D_{j^*} は正しいが、claimed D_{j^*+1} は false である。Proof は membership path、pre-state opening、一区間の machine data、claimed next digest を含む。Node は一区間だけを実行する。Worker の応答、turn clock、bisection、operator judgment は不要である。

Worker は AuditPackage 全体へ binding した timely PackageCommit と、deadline 前の客観的 DA certificate を提出できる。Host inclusion だけが失敗した場合の no-fault 返還は、この commit と certificate が存在し、後に package が valid と判定された場合に限る。Package が無い、DA でない、または invalid なら forfeit する。

Reporter は proof hash、reporter key、salt、deposit へ binding した EvidenceCommit を期限内に提出できる。最初の timely commit は一回限りの固定 HoldEnd を起動するだけで exclusive slot を得ない。Original window 内の他 reporter も同じ HoldEnd まで reveal でき、non-reveal は自身の deposit だけを burn する。Valid direct proof は hold の有無に関係なく直ちに受理する。

Valid proof の受理、Worker escrow、false-clean replayer bond、未成熟 reward の freeze は同一 state transition で行う。Evidence と maturity が同じ host unit に入る場合は evidence を先に処理する。Reporter payment 後も penalty の大半は不可逆 loss でなければならない。

Host Adapter は少なくとも次を consensus rule として公開する。

- attestor-final な Commit/Open、beacon round、threshold、non-reveal slash;
- finality 前 state の rollback、finality 後 deep reorg の failure 定義、timely evidence の再包含権;
- evidence band が客観的に満杯かを判定する predicate と deadline pause;
- checkpoint vector、KV prefix、AuditPackage を settlement finality まで pruner 対象外にする retention rule;
- object、claim、時間窓ごとの CPU、RAM、storage、disk read、network、proof queue cap.

正しい package が deadline 前に DA だったのに host inclusion だけが失敗した場合は reward を zero として Worker escrow を attempt fee 以外返還してよい。Package が無い、DA でない、または invalid なら post-open failure として forfeit する。Host majority が valid proof を期限後まで censor できる場合、OTA 単独では slash を保証しない。

7 Incentive と計算

内部 $q-2$ 区間のうち false transition 集合を S 、sample 数を m とすると、一 draw での検知率は

$$p_{\text{sample}}(S) = 1 - \frac{\binom{q-2-|S|}{m}}{\binom{q-2}{m}}. \quad (7)$$

攻撃者が最大 $g_{\max}$ 個の独立 draw から最も有利なものを選べる最悪の場合、sampled detection lower bound は

$$p_{\text{pre}}(S) = p_{\text{sample}}(S)^{g_{\max}}. \quad (8)$$

候補が相関する、または host がより強い bias を持つ場合は式 (8) を使わず、直接測定したさらに小さい lower bound を用いる。RequiredReplay が独立で実効下限 p_{full} を持つ場合、

$$p_{\text{detect}}(S) = 1 - (1 - p_{\text{pre}}(S))(1 - p_{\text{full}}). \quad (9)$$

Worker だけで成立する攻撃には L_W 、選出 replayer の結託を必要とする攻撃には式 (5) の $L_{\text{coal}}(Q)$ を用いる。Replayer 買収費を $B(Q)$ とし、proof 期間中の価格下落、burn 率、liquidity を haircut した attack coalition の最低不可逆価値を $L_{\min}(S, Q)$ 、false claim から得られる最大 protocol/external value を $V(S)$ 、objective proof の保守的確率を $p_{\text{obj}}(S, Q)$ 、margin を M とする。全許容 S と全 coalition Q について

$$p_{\text{obj}}(S, Q)L_{\min}(S, Q) > C_{\text{saved}}(S) + V(S) + B(Q) + M \quad (10)$$

を満たさなければならない。 $Q = \emptyset$ の非結託経路では式 (9) を p_{obj} の下限として使える。全 selected replayer が捕獲された経路では、permissionless watching と evidence inclusion の直接測定下限だけを数える。Nominal token 量、reputation、将来 fee は hard collateral の代わりにならない。Haircut 後価値は host state から検証可能でなければならず、式 (10) が崩れた場合は新規 claim 停止、reward 削減、または p_{full} 引き上げを行う。

Bounded-reward core profile では $V(S)$ を protocol が cap し、 $p_{\text{full}} < 1$ を許容できる。ただし担保効率はおよそ $1/p_{\text{full}}$ に悪化し、throughput の経済的上限になる。有償 inference、oracle、bridge、金融等の外部価値 profile は $p_{\text{full}} = 1$ tier または complete proof へ置く。

$m = 16$ で defect fraction が 25% なら、single draw の検知率は少なくとも $1 - 0.75^{16} \approx 98.998\%$ である。一つだけの junction では $p_{\text{sample}} \approx 16/(q - 2)$ に留まるが、value-bearing profile では式 (9) により sparse fraud の検知を p_{full} へ接続する。式 (2) により saved cost も false interval 数へ binding される。

8 限界と有効化

OTA は host finality、threshold beacon、data availability、evidence inclusion を継承する。Threshold 以上の attester 共謀、finalized open を覆す deep reorg、valid evidence の期限超過 censorship、canonical integer VM の共通 bug には安全性を提供しない。Replay signer 数も独立計算の proof ではなく、collusion risk は式 (5)(10) へ含める。

Value-bearing deployment は、厳密整数 Computation Definition、二独立実装と boundary corpus、padding/reward rule、KV-MMR と数値 $W_{\max}$ 、context cap、attester beacon と $g_{\max}$ 、bonded replayer registry、 k 、実効 p_{full} 、reporter bounty、haircut 後 collateral、Host Adapter、resource benchmark を公開するまで invalid である。一件でも wrong proof、wrong slash、missing slash、cross-implementation divergence が発生した profile は新規 admission を停止する。

この論文だけで特定 mainnet の準備完了は証明されない。Spendable reward は、bounded-reward profile の Host Adapter、Computation Definition、Parameter Set、実装監査が式 (3)(4)(10) と全 gate を満たした後にだけ有効化する。

9 結論

Open-then-Audit は、監査位置が存在する前に Worker を一つの実行へ拘束し、通常 node には少数の有界区間だけを再実行させる。厳密整数算術は honest implementation divergence を閉じ、work 比例報酬は早期 EOS と padding による cost laundering を閉じる。Append-only KV commitment は full-attention witness を定量化し、bonded threshold beacon は高 BPS host の block-hash grinding を切り離す。Bonded required replay は sparse fraud を volunteer の善意から protocol parameter へ移し、first-divergence proof は発見された不正を短い客観証拠へ変える。

安全性の主張は、18 区間が計算全体を証明することではない。Saved cost が false transition へ binding され、beacon 再試行が bond で価格付けされ、非結託 full replay の実効下限が存在し、攻撃 coalition の haircut 後 loss について式 (10) が全攻撃集合で成立することである。完全な semantic assurance が必要なら全 claim を full replay するか、別の complete proof を用いる。Sparse sampling を万能証明に見せかけないことが、本方式の単純性と安全性を同時に保つ。

10 関連研究

Refereed Delegation of Computation は複数 server へ計算を委譲し、少なくとも一者が正直である場合の検証を扱う [4]。Truebit は interactive verification game を用い、その incentive 研究は verifier dilemma に対する forced-error 方式を議論する [5, 6]。Arbitrum は off-chain VM 実行を challenge 期間と interactive fraud proof で検証し [7]、opML は optimistic fraud proof を machine-learning inference へ適用する [8]。

Open-then-Audit の差分は、one-time open で監査 sample より先に Worker を経済的に拘束すること、provisional acceptance 前に全 node が future-random sample を直接再実行すること、post-hoc dispute を interactive bisection ではなく非対話的 first-divergence proof にすること、sparse-fraud の full replay を bonded registry から protocol が選出・fund することにある。これらは complete execution proof を置き換えず、低 node 負荷の work claim と full-replay tier を分離する。

参考文献

- [1] S. Nakamoto, “Bitcoin: A Peer-to-Peer Electronic Cash System,” 2008.
- [2] R. C. Merkle, “Protocols for Public Key Cryptosystems,” IEEE Symposium on Security and Privacy, 1980.
- [3] S. Haber and W. S. Stornetta, “How to Time-Stamp a Digital Document,” Journal of Cryptology, 1991.
- [4] R. Canetti, B. Riva, and G. N. Rothblum, “Refereed Delegation of Computation,” Information and Computation, vol. 226, pp. 16–36, 2013.
- [5] J. Teutsch and C. Reitwießner, “A Scalable Verification Solution for Blockchains,” arXiv:1908.04756, 2019.
- [6] J. Koch and C. Reitwießner, “A Predictable Incentive Mechanism for TrueBit,” arXiv:1806.11476, 2018.
- [7] H. Kalodner, S. Goldfeder, X. Chen, S. M. Weinberg, and E. W. Felten, “Arbitrum: Scalable, Private Smart Contracts,” 27th USENIX Security Symposium, 2018.
- [8] K. D. Conway, C. So, X. Yu, and K. Wong, “opML: Optimistic Machine Learning on Blockchain,” arXiv:2401.17555, 2024.